



CM
ON

Cours ON : 1

Motivation et exemples :

Soit $f: \mathbb{R}^m \rightarrow \mathbb{R}$ si $C \subseteq \mathbb{R}^m$
 $(P) \rightarrow \min_{x \in C} f(x)$ on cherche $x^* \in C$

by $f(x^*) \leq f(x), \forall x \in C$
ii
 x^*

ex: $\begin{cases} f(x) = \frac{1}{2} x^T A x + b^T x \\ C = \{x \in \mathbb{R}^n \mid Ax \leq b\} \end{cases}$

quand $A = I_d$ et $b = 0$ alors $f(x) = \frac{1}{2} \|x\|^2$
On cherche alors: $\min_{x \in \{Ax \leq b\}} \frac{1}{2} \|x\|^2$



- Optimisation continue \rightarrow cadre lisse ou non lisse
- Optimisation discrète $\rightarrow C = \{0, \alpha^k\}$ ou un graphe / réseau
- Contrôle optimal \rightarrow dimension infini
- Optimisation stochastique $\rightarrow f(x) = \underset{\text{sup}}{\mathbb{E}}[l(x, y)]$

ex: $\Delta f = \sum_{i,i} \frac{\partial^2 f}{\partial x_i^2}$

$$\begin{cases} -\Delta u = f, & \Omega \subset \mathbb{R}^m \\ u = 0, & \partial\Omega \end{cases} \quad \text{à résoudre: } \min \frac{1}{2} \int_{\Omega} |\nabla u|^2 - \int_{\Omega} fu = \mathbb{E}[u]$$

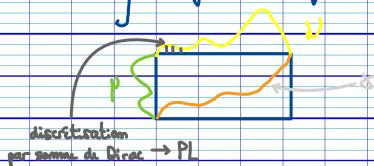
$\begin{cases} f \in L^2 \text{ et } \nabla u \in L^2 \\ u|_{\partial\Omega} = 0 \end{cases}$

ex: Transport optimal de masse

Gaspard Monge

L. Kantorovich

$$\min \int |x - y|^2 d\gamma(x, y) \text{ où } \gamma \in \Gamma(p, \mu)$$



$$\Gamma(p, \mu) = \{P \in \mathbb{R}^{m \times m}, P1_m = p \text{ et } P^T 1_m = \mu\}$$

$$\min_{P \in \Gamma(p, \mu)} \langle C, P \rangle = \sum_i c_{ij} P_{ij}$$

ex: Traitement d'image

Étant donné une image bruitée u_0 , on cherche une image débruitée u .

$$\min_u \frac{1}{2} \|u - u_0\|^2 + \lambda T_v(u) = F(u) + G(\nabla u)$$

$$= \int_{\Omega} |\nabla u|$$

ex: Apprentissage : données (a_i, y_i)

attribut
description
étiquette cellulaire (normal, anormal)

Objectif: trouver une fonction ϕ prédiction qui associe approximativement les a_i aux y_i , pour pouvoir prendre un nouvel ensemble de données $d = (a_i)$ pour prédire $z = (\hat{y}_i)$.

Rappels :

1 - Topologie :

Définition :

fermée

- La boule ouverte centrée en $c \in \mathbb{R}^m$ de rayon $r > 0$ est définie par :

$$\bar{B}(c, r) = \{x \in \mathbb{R}^m, \|x - c\| < r\}$$

Définition : intérieur

- Soit $\mathcal{U} \subseteq \mathbb{R}^m$. On dit que $c \in \mathcal{U}$ est un point intérieur de \mathcal{U} s'il existe $r > 0$ tq $B(c, r) \subseteq \mathcal{U}$

- On définit $\text{int}(\mathcal{U}) := \dot{\mathcal{U}}$ par $\{x \in \mathcal{U}, B(x, r) \subseteq \mathcal{U}, \text{ pour } r > 0\}$

ex: $\text{int}(\bar{B}(0, 1)) = B(0, 1)$

$\text{int}([0, 1]) = (0, 1)$

$\text{int}(\mathbb{R}_+) = \mathbb{R}_+^*$

Définition : ouverts

- $\mathcal{U} \subseteq \mathbb{R}^m$ est un ouvert si: $\forall x \in \mathcal{U}, \exists r > 0, B(x, r) \subseteq \mathcal{U}$

Définition : fermés

\mathcal{U} fermé $\leftrightarrow \mathcal{U}^c$ ouvert

- \mathcal{U} est fermé si: $\forall (x_m)_m \in \mathcal{U}$ tq $x_m \rightarrow x^*$, alors $x^* \in \mathcal{U}$

Proposition:

- Supposons que S est un fermé, alors $\forall d \in \mathbb{R}$:

$$\begin{aligned} \text{Lex}(f, d) &= \{\boldsymbol{x} \in S, f(\boldsymbol{x}) \leq d\} \\ \text{Com}(f, d) &= \{\boldsymbol{x} \in S, f(\boldsymbol{x}) = d\} \end{aligned} \quad] \text{ sont des fermés}$$

Definition:

- $S \subseteq \mathbb{R}^m$ est **bornée** s'il existe $r > 0$ tq $B(0, r) \supseteq S$

- $S \in A$ **compact** s'il est fermé borné

Differentiabilité:

- Soit $f: S \subseteq \mathbb{R}^m \rightarrow \mathbb{R}$, $\boldsymbol{x} \in S$ et $d \in \mathbb{R}^m \setminus \{0\}$.

- Si la limite $\lim_{t \rightarrow 0^+} \frac{f(\boldsymbol{x} + t\boldsymbol{d}) - f(\boldsymbol{x})}{t}$ existe, on l'appelle dérivée directionnelle.

- On la note : $f'(\boldsymbol{x}; \boldsymbol{d})$

- Pour $i = 1, \dots, m$ la dérivée de f dans la direction e_i est notée : $\frac{\partial f}{\partial x_i}(\boldsymbol{x})$

- Si $\frac{\partial f}{\partial x_i}(\boldsymbol{x})$ existe pour tout \boldsymbol{x} , le gradient de f est :

$$\nabla f(\boldsymbol{x}) = \left(\frac{\partial f}{\partial x_1}(\boldsymbol{x}), \dots, \frac{\partial f}{\partial x_m}(\boldsymbol{x}) \right)^T$$

- On a, $f'(\boldsymbol{x}; \boldsymbol{d}) = \nabla f(\boldsymbol{x})^T \cdot \boldsymbol{d}$

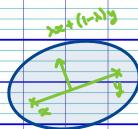
II - Convexité:

Définition:

Soit $C \subseteq \mathbb{R}^m$. On dit que C est convexe si :

$$\forall \lambda \in [0,1], \lambda x + (1-\lambda)y \in C, \forall x,y \in C$$

ex:



les boules: B , les hyperplans: $H = \{x \in \mathbb{R}^m, a^T x = b\}$

contre-exemple:



est non convexe

Proposition: Intersection de convexes

Soient $C_i \subseteq \mathbb{R}^m$ des ensembles convexes avec $i \in I$, alors :

$$C = \bigcap_{i \in I} C_i \text{ est convexe}$$

Théorème: Préservation de la convexité

1) Soient $C_1, \dots, C_m \subseteq \mathbb{R}^m$ des convexes de \mathbb{R}^m et $\lambda_1, \dots, \lambda_m \in \mathbb{R}$ alors :

$$C = \sum_{i=1}^m \lambda_i C_i \text{ est convexe}$$

2) le produit : $\prod_{i=1}^m C_i$ est convexe

3) Si $C \subseteq \mathbb{R}^m$ est convexe et $A \in \mathbb{R}^{m \times m}$, alors :

$$A(C) = \{Ax, x \in C\} \text{ est convexe}$$

Définition: Enveloppe convexe

Soient $(x_1, \dots, x_m) \in \mathbb{R}^m$. On appelle combinaison convexe des x_i :

$$\sum_{i=1}^m \lambda_i x_i \text{ avec } \lambda_i \geq 0, \sum_{i=1}^m \lambda_i = 1$$

Théorème:

Soit $C \subseteq \mathbb{R}^m$ un convexe et $x_1, \dots, x_m \in C$ alors:

$$\forall \lambda \in \Delta_m, \sum_{i=1}^m \lambda_i x_i \in C$$



$$\text{avec } \Delta_m = \{ \lambda = (\lambda_1, \dots, \lambda_m), \lambda_i \geq 0 \text{ et } \sum_{i=1}^m \lambda_i = 1 \}$$

Définition: Enveloppe

Soit $S \subseteq \mathbb{R}^m$. On appelle enveloppe convexe de S : $\text{Conv}(S)$ l'ensemble de toutes les combinaisons convexes de S :

$$\text{Conv}(S) = \left\{ \sum_{i=1}^m \lambda_i x_i \text{ avec } x_i \in S, \lambda_i \geq 0 \text{ et } \sum_{i=1}^m \lambda_i = 1 \right\}$$

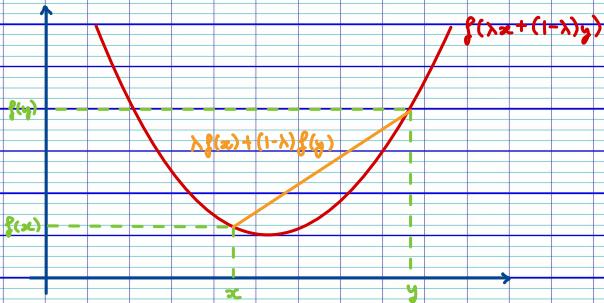
Définition: Fonctions convexes

Soit $f: C \rightarrow \mathbb{R}$. On dit que f est convexe si:

$$f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y), \forall \lambda \in [0,1] \text{ et } \forall x, y \in C$$

On dit que f est strictement convexe si :

$$f(\lambda x + (1-\lambda)y) < \lambda f(x) + (1-\lambda)f(y), \forall \lambda \in (0,1) \text{ et } \forall x, y \in C$$



Définition : Convexité

Si $-f$ est convexe, on dit que f est concave.

ex: les normes $\|.\|_1$ et $\|.\|_\infty$ sont convexes.

les fonctions affines : $f(x) = a^T x + b$ sont convexes.

Théorème: Inégalité de Jensen

Soit $f: C \rightarrow \mathbb{R}$ convexe alors :

$\forall x_1, \dots, x_n \in C$ et $\lambda \in \Delta_n$

$$f\left(\sum_{i=1}^n \lambda_i x_i\right) \leq \sum_{i=1}^n \lambda_i f(x_i)$$

Théorème:

1. Si f est convexe et $d \in \mathbb{R}^+$ alors df est convexe
2. Si f_1, \dots, f_m sont convexes sur $C \subseteq \mathbb{R}^m$ alors $\sum_{i=1}^m f_i$ est convexe sur C
3. Si f_1, \dots, f_m sont convexes sur $C \subseteq \mathbb{R}^m$ alors $f(x) = \sup_{i \in \{1, \dots, m\}} f_i(x)$ est convexe sur C .

Théorème : Caractérisation des fonctions convexes différentiables

Soit $f: C \subseteq \mathbb{R}^m \rightarrow \mathbb{R}$ différentiable alors :

$$\begin{aligned} f \text{ convexe} &\Leftrightarrow \forall x, y \in C, f(y) \geq f(x) + \nabla f(x)^T(y - x) \\ &\Leftrightarrow (\nabla f(x) - \nabla f(y))^T \cdot (y - x) \geq 0 \end{aligned}$$

De plus, si f est C^2 alors f convexe $\Leftrightarrow \nabla^2 f(x) \geq 0, \forall x \in C$.

ex: $y^T \nabla^2 f(x) y \geq 0 \Leftrightarrow \lambda_{\min}(\nabla^2 f(x)) \geq 0$

\downarrow plus petit valeur propre

Opérateur matriciel: $\langle A(x) - A(y), x - y \rangle \geq 0$

- ex:
1. $m = 1, f(x) = -\log(x)$ est convexe sur \mathbb{R}_+^*
 2. $f(x) = \frac{1}{2} x^T A x$ et $A \in \mathbb{S}^m$ (mat sym $A^T = A$)
- Mq f convexe $\Leftrightarrow A \in \mathbb{S}_+^m$

Rémarque: Fonction à valeurs dans $\mathbb{R} \cup \{+\infty\}$

ex: $S \subseteq \mathbb{R}^m$, l'indicateur de S : $\delta_S(x) = \begin{cases} 0 & \text{si } x \in S \\ +\infty & \text{sinon} \end{cases}$

Soit $f: \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$, on note :

$$\text{dom}(f) = \{x \in \mathbb{R}^m, f(x) < +\infty\}$$

On dit que f est propre si $f \neq +\infty$, si $\exists x_m \in \mathbb{R}^m$ tq $f(x_m) < +\infty$

ex: 1. Fonction support (ou d'appui). Soit $S \subseteq \mathbb{R}^m$:

$$S^*(x) = \sup_{y \in S} x^T y$$

$$2. f: \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}, f^*(x) = \sup_{y \in S} (x^T y - f(y))$$

Définition: Sous ensemble de niveau de fonction (sub) level sets

Soit $f: S \subseteq \mathbb{R}^m \rightarrow \mathbb{R}$. le sous-ensemble de f de niveau $a \in \mathbb{R}$ est :

$$\text{Lev}(f, a) = \{x \in S, f(x) \leq a\}$$

Théorème:

Soit $f: C \subseteq \mathbb{R}^m \rightarrow \mathbb{R}$ une fonction convexe, avec C convexe, alors:

$\forall a \in \mathbb{R}$, $\text{Lev}(f, a)$ est convexe

⚠ Réciproque fausse

Définition:

Une fonction $f: C \rightarrow \mathbb{R}$ avec C convexe est dite quasi-convexe si :

$\forall a \in \mathbb{R}$, $\text{Lev}(f, a)$ sont convexes.

ex: $f(x) = \sqrt{|x|}$

pour $a < 0$: $\text{lev}(f, a) = \emptyset$

pour $a \geq 0$: $x \in \text{lev}(f, a)$ si $\sqrt{|x|} \leq a$ soit $|x| \leq a^2$ ie $[-a^2, a^2]$

Optimisation convexe: $\min_{x \in C} f(x)$ où $\begin{cases} f \text{ convexe} \\ C \text{ convexe} \end{cases}$

Rappel: Soit $x^* \in C$

On dit que x^* est un niveau local de f sur C si il existe $r > 0$ tq:

$$f(x^*) \leq f(x), \forall x \in C \cap B(x^*, r)$$

On dit que x^* est un minimum global de f sur C si :

$$f(x^*) \leq f(x), \forall x \in C$$

Théorème:

Soit $f: C \subset \mathbb{R}^m \rightarrow \mathbb{R}$ convexe avec C convexe. Soit $x^* \in C$, un minimum local de f sur C . Alors x^* est un minimum global de f .

Précise:

Soit $x^* \in C$ un minimum local de f sur C . Donc $\exists r > 0$ tq:

$$f(x^*) \leq f(x), \forall x \in C \cap B(x^*, r)$$

Soit $y \in C \setminus \{x^*\}$, mq $f(x^*) \leq f(y)$

Soit $t \in [0, 1]$, on considère : $\bar{x} = x^* + t(y - x^*)$ tq $\bar{x} \in C \cap B(x^*, r)$

Par convexité de C on a: $\bar{x} \in C \cap B(x^*, r)$ et par convexité de f :

$$f(x^*) \leq f(\bar{x}) = f(x^* + t(y - x^*))$$

$$\leq t f(y) + (1-t) f(x^*)$$

donc $t f(x^*) \leq t f(y)$ ie x^* est un minimum global de f .

De même, on démontre :

Théorème:

Soit $f : C \rightarrow \mathbb{R}$ strictement convexe.

Si $x^* \in C$ est un minimum strictement local alors x^* est un minimum strictement global.

Convexité de l'ensemble des minimiseurs:

Notation: On note $S := \underset{x \in C}{\operatorname{argmin}} f(x)$ l'ensemble des minimiseurs de f sur C .

Théorème:

Soit $f : C \subset \mathbb{R}^m \rightarrow \mathbb{R}$ une fonction convexe, alors S est convexe.

Si f est strictement convexe alors S contient au plus un élément.

Preuve:

Si $S = \emptyset$, rien à démontrer.

Sinon, on peut écrire $S = C \cap \operatorname{lev}(f, f^*)$ qui est convexe par intersection de convexes.

Autrement, soient $x, y \in S$ et $\lambda \in [0, 1]$ alors:

$$\begin{aligned} f(\lambda x + (1-\lambda)y) &\leq \lambda f(x) + (1-\lambda)f(y) \\ &= \lambda f^* + (1-\lambda)f^* = f^* \end{aligned}$$

donc $\lambda x + (1-\lambda)y \in S$

Si f est strictement convexe...

Supposons qu'il existe $x, y \in S$ où $x \neq y$, alors $\frac{1}{2}x + \frac{1}{2}y \in C$ et on a : $f\left(\frac{1}{2}x + \frac{1}{2}y\right) < \frac{1}{2}f(x) + \frac{1}{2}f(y) = f^*$ ce qui est absurde.

Projection orthogonal :

Soit $C \subseteq \mathbb{R}^n$ un convexe fermé.

Définition:

L'opérateur de projection orthogonale sur C est l'application (noté P_C ou Π_C)

$$P_C : \begin{cases} \mathbb{R}^n \rightarrow C \\ z \rightarrow P_C(z) = \underset{y \in C}{\operatorname{argmin}} \|y - z\|^2 \end{cases}$$

Théorème:

Soit C un convexe fermé non vide dans \mathbb{R}^n , alors:

$\min_{y \in C} \|x - y\|^2$ admet une unique solution ($x^* = P_C(x)$)



ex: Pour $C = B(0, r)$, $r > 0$: $P_C(z) = \begin{cases} z & \text{si } \|z\| \leq r \\ \frac{r}{\|z\|} z & \text{sinon} \end{cases}$

$$\left\| \frac{r}{\|z\|} z \right\| = r$$

Théorème:

Soit C un convexe fermé non vide de \mathbb{R}^n , alors pour $z \in \mathbb{R}^n$:

$$z = P_C(z) \iff (z - z)^T (y - z) \leq 0 \quad \forall y \in C$$

Théorème:

Soit C un convexe fermé non vide de \mathbb{R}^m .

1. $\forall v, w \in \mathbb{R}^m, (P_C(v) - P_C(w))^T (v-w) \geq \|P_C(v) - P_C(w)\|^2$
2. $\forall v, w \in \mathbb{R}^m, \|P_C(v) - P_C(w)\| \leq \|v-w\|$ ← CS

Inégalités: Young: $ab \leq \frac{a^2}{2} + \frac{b^2}{2}$
CS: $ab \leq |a||b|$

III - Descente: méthode du gradient

Motivation: $\min_{x \in \mathbb{R}^m} f(x)$

construire x_0, x_1, \dots, x_m

$\leftarrow f(x_0) \rightarrow g^*$ ← valeur optimale

si \exists possible $x_m \rightarrow x^*$ (dans un sens à préciser)

Définition: direction de descente

Soit $f: \mathbb{R}^m \rightarrow \mathbb{R}$. On dit que $0 \neq d \in \mathbb{R}^m$ est une direction de descente de f en $x \in \mathbb{R}^m$

si $f'(x, d) = \nabla f(x)^T \cdot d < 0$

Lemme:

Soit $f \in C'(\mathbb{R}^m)$ et $x \in \mathbb{R}^m$.

Si d est une direction de descente de f en x alors :

$$\exists \epsilon > 0 \text{ tq } \forall t \in [0, \epsilon] : f(x + t d) < f(x)$$

Schématiquement :

Initialisation: $x_0 \in \mathbb{R}^n$

Pour $k = 0, 1, 2, \dots$

1. choisir d_k

2. choisir t_k tq : $f(x_k + t_k d_k) < f(x_k)$

3. prendre $x_{k+1} = x_k + t_k d_k$

4. si un critère d'arrêt vérifie : $\|\nabla f(x_k)\| \leq \epsilon$

on renvoie x_{k+1}

La recherche d'un pas t_k s'appelle la méthode de recherche linéaire, qui consiste à :

$t_k \in \arg\min_{t \geq 0} g(t) = f(x_k + t d_k)$

Pas constant: $t_k = \bar{t}, \forall k$

Recherche linéaire exacte: résoudre (γ)

Back-tracking : pour $s > 0, \alpha, \beta \in]0, 1[$,

tant que $f(x_k) - f(x_k + t_k d_k) < -\alpha t_k \nabla f(x_k)^T d_k$
 $t_k \leftarrow \beta t_k$

donc $t_k = s\beta^{ik}$ avec i_k le plus petit entier tq:

$f(x_k) - f(x_k + s\beta^{i_k} d_k) \geq -s\beta^{i_k} \nabla f(x_k)^T d_k$

Exemple: recherche linéaire exacte

$$f(x) = x^T A x + 2b^T x + c \quad \text{avec } \begin{cases} A \in \mathbb{S}_+^n \\ b \in \mathbb{R}^n \\ c \in \mathbb{R} \end{cases}$$

Soit d une direction de descente de f en $x \in \mathbb{R}^n$.

On considère : $\min_{t \geq 0} g(t) = f(x + t d)$

On a : $g'(t) = 2(d^T A d)t + 2d^T \nabla f(x)$

donc $g'(t) = 0 \Leftrightarrow t = -\frac{d^T \nabla f(x)}{d^T A d} \quad \text{car } A > 0$

Descente du gradient :

Pour cette méthode, on prend $d_k = -\nabla f(x_k)$

$$\text{On a : } f'(x_k - \nabla f(x_k)) = -\nabla f(x_k)^\top \nabla f(x_k) = -\|\nabla f(x_k)\|^2 < 0$$

(pour x_k tq $\nabla f(x_k) \neq 0$)

Méthode du gradient :

Donnée : tolérance $\epsilon > 0$ (pour la critère d'arrêt)

Initialisation: $x_0 \in \mathbb{R}^m$

Etapes : pour $k = 0, 1, 2, \dots$

1. choisir t_k avec une recherche linéaire sur :

$$g(t) = f(x_k - t_k \nabla f(x_k))$$

$$2. x_{k+1} = x_k - t_k \nabla f(x_k)$$

3. arrêt si : $\|\nabla f(x_k)\| \leq \epsilon$

Analyse de convergence :

Soit $f \in C_0^{1,1}(\mathbb{R}^m)$ i.e. f est C^1 et $\|\nabla f(x) - \nabla f(y)\| \leq L\|x-y\|$, $\forall y \in \mathbb{R}^m$

ex: 1. $f(x) = a^T x + b \in C_0^1$

2. $f(x) = x^T A x + 2b^T x + c$, $\nabla f(x) = 2(Ax + b)$

$$\|\nabla f(x) - \nabla f(y)\| = 2\|(Ax + b) - (Ay + b)\| \leq \underline{L} \|A\| \|x - y\|$$

Théorème:

Soit $f \in C^2(\mathbb{R}^m)$, alors $f \in C_0^{1,1}(\mathbb{R}^m) \Leftrightarrow \|\nabla^2 f(x)\| \leq L$, $\forall x \in \mathbb{R}^m$

Lemme:

Soit $f \in C_c^2(\mathbb{R}^n)$, alors $\forall x \in \mathbb{R}^n$ et $\forall t > 0$:

$$f(x) - f(x - t\nabla f(x)) \geq t \left(1 - \frac{L}{2}\right) \|\nabla f(x)\|^2$$

Pas constraint tq $t_k = \bar{t} \in [0, \frac{\epsilon}{L}]$ on a:

$$f(x_n) - f(x_n - \bar{t} \nabla f(x_n)) \geq \bar{t} \left(1 - \frac{L}{2}\right) \|\nabla f(x_n)\|^2$$

Pour avoir une plus grande borne, on regarde la fonction $t \rightarrow t(1 - \frac{L}{2})$ pour $t \in [0, \frac{\epsilon}{L}]$

Dans on trouve $\bar{t} = \frac{1}{L}$

$$\begin{aligned} \text{On a donc: } f(x_n) - f(x_{n+1}) &= f(x_n) - f(x_n - \frac{1}{L} \nabla f(x_n)) \\ &\geq \frac{1}{L} \left(1 - \frac{L}{2} \cdot \frac{1}{L}\right) \|\nabla f(x_n)\|^2 \\ &= \frac{1}{2L} \|\nabla f(x_n)\|^2 \end{aligned}$$

Recherche linéaire exacte: $x_{n+1} = x_n - t_k \nabla f(x_n)$

avec $t_k \in \underset{t \geq 0}{\operatorname{argmin}} g(t) = f(x_n - t \nabla f(x_n))$

Dans ce cas, par définition de t_k : $f(x_n - t_k \nabla f(x_n)) \leq f(x_n - \frac{1}{L} \nabla f(x_n))$

$$\begin{aligned} \text{donc: } f(x_n) - f(x_{n+1}) &\geq f(x_n) - f(x_n - \frac{1}{L} \nabla f(x_n)) \\ &\geq \frac{1}{2L} \|\nabla f(x_n)\|^2 \end{aligned}$$

Pour le backtracking (avec $s > 0$ et $\alpha, \beta \in [0, 1[$)

On choisit $t_k > \min \{ s, \frac{2(1-\alpha)\beta}{L} \}$

Résumé:

Soit $f \in C_c^2(\mathbb{R}^n)$ et (x_{n+1}) la suite générée par la méthode de descente du gradient, alors $f(x_n) - f(x_{n+1}) \geq M \|\nabla f(x_n)\|^2$

avec $M = \sqrt{\bar{t} \left(1 - \frac{L}{2}\right)}$

$$\begin{cases} \frac{1}{L} & \text{si } \min \{ s, \frac{2(1-\alpha)\beta}{L} \} \leq \bar{t} \\ \frac{1}{2L} & \text{sinon} \end{cases}$$

Théorème: Convergence de gradients

Soit $f \in C^1_c(\mathbb{R}^n)$ et $(x_n)_n$ suite générée par la méthode du gradient.

Supposons que f est bornée inférieurement, i.e. $\exists c \in \mathbb{R}$ tq $f(x) \geq c \quad \forall x \in \mathbb{R}^n$, alors:

1. $(f(x_n))_n$ est décroissante et $f(x_{n+1}) < f(x_n)$ sauf si $\nabla f(x_n) = 0$
2. $\nabla f(x_n) \xrightarrow{n \rightarrow \infty} 0$

Démonstration:

- 1) On sait que $f(x_n) - f(x_{n+1}) \geq M \|\nabla f(x_n)\|^2 \geq 0$ donc quand $\nabla f(x_n) \neq 0$, $f(x_{n+1}) < f(x_n)$
- 2) Comme $(f(x_n))$ est décroissante et f bornée inf., alors $(f(x_n))$ est convergente, pour la suite $f(x_n) - f(x_{n+1}) \xrightarrow{n \rightarrow \infty} 0$, donc d'après le calcul précédent au point 1) $\|\nabla f(x_n)\| \xrightarrow{n \rightarrow \infty} 0$

Théorème:

Sous les mêmes hypothèses, on a $\forall n \geq 0$:

$$\min_{k=0, \dots, m} \|\nabla f(x_k)\| \leq \sqrt{\frac{f(x_0) - f^*}{M(m+1)}}$$

Rappels:

Méthode de Newton pour chercher les zéros d'une fonction.

Soit $f: \mathbb{R} \rightarrow \mathbb{R}$, on cherche à résoudre $f(t) = 0$.

On regarde l'approximation d'ordre 1 de f autour d'un point $t_0 \in \mathbb{R}$ et

$$\tilde{f}(t) = f(t_0) + f'(t_0)(t - t_0)$$

$$\text{donc } \tilde{f}(t) = 0 \Rightarrow t = t_0 - \frac{f(t_0)}{f'(t_0)}$$

$$\text{Itérativement, } t_{m+1} = t_m - \frac{f(t_m)}{f'(t_m)}$$

De même, si $g: \mathbb{R}^n \rightarrow \mathbb{R}^n$, pour résoudre $g(x) = 0_{\mathbb{R}^n}$, on remplace $g(x)$ par:

$$\tilde{g}(x) = g(x) + \nabla g(x_0)(x - x_0) \text{ autour de } x_0 \in \mathbb{R}^n$$

Donc, en supposant que $\det(\nabla g(x_0)) \neq 0$, on obtient que:

$$x_{m+1} = x_m - (\nabla g(x_m))^{-1} g(x_m)$$

En optimisation, pour résoudre $\min_{x \in \mathbb{R}^n} f(x)$, on considère le système linéaire $\nabla f(x) = 0$.

Pour rappel:

$\nabla f(x^*) = 0$ et f convexe revient à dire que x^* est optimal, on trouve donc:

$$x_{m+1} = x_m - (\nabla^2 f(x_m))^{-1} \nabla f(x_m)$$

Méthode de Newton:

Soit $f: \mathbb{R}^n \rightarrow \mathbb{R}$ C² et $x_0 \in \mathbb{R}^n$.

$$\text{On considère } \tilde{f}(x) = f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle + \frac{1}{2} \langle \nabla^2 f(x_0)(x - x_0), x - x_0 \rangle$$

La méthode de Newton, revient à générer la suite:

$$x_{m+1} = \underset{x \in \mathbb{R}^n}{\operatorname{argmin}} \tilde{f}(x) = f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle + \frac{1}{2} \langle \nabla^2 f(x_0)(x - x_0), x - x_0 \rangle$$

dans ce cas :

$$\nabla \tilde{f}(x_m) = 0 \text{ donne : } \nabla f(x_0) + \nabla^2 f(x_0)(x_m - x_0) = 0$$

$$\text{soit } x_{m+1} = x_0 - (\nabla^2 f(x_0))^{-1} \nabla f(x_0) \text{ où } \nabla^2 f(x_0) \in \mathbb{S}_{++}^n$$

donc la méthode de Newton est une méthode de descente avec comme direction :

$$d_f = -(\nabla^2 f(x_0))^{-1} \nabla f(x_0)$$

Théorème : Convergence quadratique

Soit $f \in C^2$ et supposons que :

$$1. \exists m > 0 \text{ tq } \nabla^2 f(x) \geq m I_m, \forall x \in \mathbb{R}^m$$

$$2. \exists L > 0 \text{ tq } \| \nabla^2 f(x) - \nabla^2 f(y) \| \leq L \|x-y\|, \forall x, y \in \mathbb{R}^m$$

Soit (x_n) la suite générée par la méthode de Newton, alors :

$$\forall k \geq 0, \|x_{k+1} - x_k\|^2 \leq \frac{L}{2m} \|x_k - x^*\|^2$$

Méthode du gradient projeté :

On cherche $\min_{x \in C} f(x)$ et $C \subseteq \mathbb{R}^m$ convexe fermé.

Théorème :

Soit $f : C \subseteq \mathbb{R}^m \rightarrow \mathbb{R}$ C^2 et $s > 0$, alors x^* est un point stationnaire de (P) si et seulement si

$$x^* = P_C(x^* - s \nabla f(x^*))$$

Remarque : on peut minimiser sur \mathbb{R}^m avec : $\min_{x \in \mathbb{R}^m} f(x) + \frac{\lambda}{2} \|x\|^2$

Indicateur matriciel

Gradient projeté :

Soit $\epsilon > 0$.

Initialisation : prendre $x_0 \in C$

Étapes : 1. choisir t_k

$$2. x_{k+1} = P_C(x_k - t_k \nabla f(x_k))$$

3. si critère d'arrêt vérifié, on s'arrête et on renvoie x_{k+1} .

Lemme :

Soit $f \in C_1^{\infty}(C)$, avec C convexe fermé

$\forall x \in C$ et $\forall t \in (0, \frac{1}{L})$, on a :

$$f(x) - f(P_c(x - t\nabla f(x))) \geq t\left(1 - \frac{Lt}{2}\right) \left\| \frac{1}{t}(x - P_c(x - t\nabla f(x))) \right\|^2$$

Démonstration:

Utiliser la lemme de descente avec :

$$y = P_c(x - t\nabla f(x)) + \text{propriété de projection}$$

Pour $M > 0$, on définit :

$$G_M(x) = M(x - P_c(x - \frac{1}{M}\nabla f(x)))$$

Quand $C = \mathbb{R}^m$, $G_M(x) = \nabla f(x)$

Le lemme précédent devient : $f(x) - f(P_c(x - t\nabla f(x))) \geq t\left(1 - \frac{Lt}{2}\right) \left\| G_{\frac{1}{L}}(x) \right\|^2$ mesure d'optimalité

Cas convexes

Soit $f \in C_1^{\infty}(C)$ convexe

Théorème:

Sous ces conditions, la suite générée par la méthode du gradient projeté avec $t_k = t^* \in [0, \frac{1}{L}]$ vérifie :

$$1. x_k \xrightarrow{k \rightarrow \infty} x^* \in S = \operatorname{argmin}_{x \in C} f(x)$$

$$2. f(x_k) - f^* \leq \frac{1}{2t^*k} \|x_0 - x^*\|^2$$

Conditions d'optimalité: contraintes affines

Soit (P) : $\begin{cases} \min f(x) \\ \text{avec } f \in C^1 \text{ et } a_1, \dots, a_m \in \mathbb{R}^m \text{ et } b_1, \dots, b_m \in \mathbb{R}^m \\ a_i^T x \leq b_i, i=1, \dots, m \end{cases}$

Soit x^* un minimum local de (P) .

$$\text{Alors, } \exists \lambda_1, \dots, \lambda_m \geq 0 \text{ tq : } \begin{cases} \nabla f(x^*) + \sum_{i=1}^m \lambda_i a_i = 0 \\ \lambda_i (a_i^T x^* - b_i) = 0, \forall i = 1, \dots, m \end{cases}$$

Il s'agit d'une condition nécessaire.

On a équivalence lorsque f est convexe :

$$x^* \text{ minimum de } f \Leftrightarrow \exists \lambda_1, \dots, \lambda_m \geq 0 \text{ tq on appelle } \lambda \text{ le multiplicateur de Lagrange associé à la contrainte } a_i^T x \leq b_i : \begin{cases} \nabla f(x^*) + \sum_{i=1}^m \lambda_i a_i = 0 \\ \lambda_i (a_i^T x^* - b_i) = 0, \forall i = 1, \dots, m \end{cases}$$

On considère le problème : (P) $\begin{cases} \min f(x) \\ \text{avec } a_i^T x \leq b_i, i=1, \dots, m \\ c_j^T x = d_j, j=1, \dots, p \end{cases}$

Théorème: condition nécessaire

1) Si x^* est un minimum de (P) : $\exists \lambda_1, \dots, \lambda_m \geq 0$ et $p_1, \dots, p_p \in \mathbb{R}$ tq :

$$\begin{cases} \nabla f(x^*) + \sum_{i=1}^m \lambda_i a_i + \sum_{j=1}^p p_j c_j = 0 \\ \lambda_i (a_i^T x^* - b_i) = 0, \forall i = 1, \dots, m \end{cases}$$

2) Condition suffisante lorsque f est convexe :

si f est convexe et x^* admissible (ie vérifie $a_i^T x \leq b_i, i=1, \dots, m$ tq $\exists \lambda_1, \dots, \lambda_m \geq 0$ et p_1, \dots, p_p

$$\text{vérifiant } \begin{cases} \nabla f(x^*) + \sum_{i=1}^m \lambda_i a_i + \sum_{j=1}^p p_j c_j = 0 \\ \lambda_i (a_i^T x^* - b_i) = 0, \forall i = 1, \dots, m \end{cases}$$

alors x^* est optimal pour (P)

Remarque:

- les multiplicateurs de Lagrange associé à $a_i^T x \leq b$ sont toujours dans \mathbb{R}_+ .
- Un point x^* vérifiant (C*) est dit point KKT (Karush-Kuhn-Tucker).

Plus généralement, on considère (P):

$$\begin{cases} \min f(x) \\ \text{avec } f, g, h \in C^1 \\ g_i(x) \leq 0, \quad i=1, \dots, m \\ h_j(x) = 0, \quad j=1, \dots, p \end{cases}$$

Définition:

On appelle Lagrangien associé à (P), la fonction:

$$L(x, \lambda, \mu) = f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{j=1}^p \mu_j h_j(x)$$

L'équivalent de l'équation $\nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla g_i(x^*) + \sum_{j=1}^p \mu_j \nabla h_j(x^*) = 0$, par le problème (P):

$$\begin{cases} \nabla_x L(x^*, \lambda, \mu) = 0 \\ \nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla g_i(x^*) + \sum_{j=1}^p \mu_j \nabla h_j(x^*) = 0 \end{cases}$$

KKT

$$\begin{cases} \nabla L = 0 \\ \text{2nd principe } L = 0 \\ \text{contraintes} \end{cases} \quad + \text{ convexe} = \min$$

Remarque: le problème $\min f(x)$ peut s'écrire de la forme:

$$\begin{cases} \min f(x) \\ \text{avec } A^T x \leq b \\ Ax \leq b \\ Cx = d \end{cases}$$

et son Lagrangien s'écrit: $L(x, \lambda, \mu) = f(x) + \lambda^T (Ax - b) + \mu^T (Cx - d)$

ex: $\begin{cases} \min f(x, y, z) \text{ où } f(x, y, z) = \frac{1}{2} (x^2 + y^2 + z^2) \\ x + y + z = 3 \end{cases}$

Le Lagrangien du problème s'écrit:

$$L(x, y, z, \lambda) = \frac{1}{2} (x^2 + y^2 + z^2) + \lambda (x + y + z - 3)$$

En écrivant les conditions KKT, on trouve:

$$\begin{cases} \nabla L(x, y, z, \lambda) = 0 \quad \text{on a } \frac{\partial L}{\partial x} = x + \lambda, \quad \frac{\partial L}{\partial y} = y + \lambda \\ (\lambda(x + y + z - 3) = 0 \\ \frac{\partial L}{\partial z} = z + \lambda \end{cases}$$

donc $\nabla L = 0$ donne $x=y=z=-\lambda$

comme $x+y+z=3$, on trouve $\lambda=-1$

le système: $\begin{cases} \frac{\partial L}{\partial x} = 0 \text{ donne } x=y=z=1 \\ \frac{\partial L}{\partial z} = 0 \\ \frac{\partial L}{\partial y} = 0 \\ \frac{\partial L}{\partial \lambda} = 0 \end{cases}$

△ nous avons utilisé le fait que f est convexe, donc les conditions KKT sont suffisantes pour affirmer que $(x,y,z) = (1,1,1)$ est solution minimale.

Application: calcul de projection orthogonale

1) Projection sur un sous-espace affine, $y \in \mathbb{R}^m$:

$$\min_{x \in C} f(x) \text{ avec } \begin{cases} f(x) = \|x-y\|^2, A \in \mathbb{R}^{m,m}, b \in \mathbb{R}^m \text{ et } r_A(A)=m \\ C = \{x \in \mathbb{R}^m, Ax=b\} \end{cases}$$

les conditions KKT sont nécessaires et suffisantes pour trouver $P_C(y)$.

le lagrangien du problème s'écrit:

$$L(x, \lambda) = \|x-y\|^2 + 2A^T(x-b)$$

$$\text{On a } \nabla_x L(x, \lambda) = 2(x-y) + 2A^T\lambda = 2x - 2(y-A^T\lambda)$$

$$\text{KKT: } \begin{cases} 2x - 2(y-A^T\lambda) = 0 \Rightarrow x = y - A^T\lambda \\ Ax = b \end{cases}$$

On remplace $x=y-A^T\lambda$ dans $Ax=b$ pour trouver $A(y-A^T\lambda)=b$ soit $\lambda = (AA^T)^{-1}(Ay-b)$

$$\text{donc } P_C(y) = y - A^T\lambda = y - A^T(AA^T)^{-1}(Ay-b)$$

Cas particulier: $C = H = \{x, a^T x = b\}$ $0 \neq a \in \mathbb{R}^m$ et $b \in \mathbb{R}$

$$\text{On trouve: } P_H(y) = y - \frac{(a^Ty - b)}{\|a\|^2} a.$$

2) Projection sur un demi-espace : $H = \{x \in \mathbb{R}^n, a^T x \leq b\}$, $0 \neq a \in \mathbb{R}^n$ et $b \in \mathbb{R}$

On cherche à résoudre: $\min_{x \in H} \|x-y\|^2$

le lagrangien du système s'écrit :

$$L(x, \lambda) = \|x-y\|^2 + 2\lambda(a^Tx - b) \text{ avec } \lambda \geq 0$$

Avec KKT : $\begin{cases} \nabla_{\mathbf{x}} l(\mathbf{x}, \lambda) = 0 \Rightarrow 2(\mathbf{a}^T \mathbf{x} - b) + 2\lambda = 0 \\ \lambda(\mathbf{a}^T \mathbf{x} - b) = 0 \\ \mathbf{a}^T \mathbf{x} \leq b \\ \lambda \geq 0 \end{cases}$

si $\lambda = 0$: $\mathbf{x} = \mathbf{y}$ donc $P_{\mathbb{H}^\perp}(\mathbf{y}) = \mathbf{y}$ (car $\mathbf{a}^T \mathbf{x} = \mathbf{a}^T \mathbf{y}$)

si $\lambda > 0$: on trouve $\mathbf{x} = \mathbf{y} - \lambda \mathbf{a}$

$$\text{on a: } \mathbf{a}^T(\mathbf{y} - \lambda \mathbf{a}) = b \Rightarrow \|\mathbf{a}^T \mathbf{y} - \lambda \|\mathbf{a}\|^2\| = b \text{ soit } \lambda = \frac{\mathbf{a}^T \mathbf{y} - b}{\|\mathbf{a}\|^2} > 0$$

Finalement : $P_{\mathbb{H}^\perp}(\mathbf{y}) = \begin{cases} \mathbf{y} & \text{si } \mathbf{a}^T \mathbf{y} \leq b \\ \mathbf{y} - \frac{\mathbf{a}^T \mathbf{y} - b}{\|\mathbf{a}\|^2} \mathbf{a} & \text{sinon} \end{cases}$

3) Projection sur la boule : $\min \|\mathbf{x} - \mathbf{y}\|^2$

$$\mathbf{x} \in \overline{B(0, r)} = \{\mathbf{x} : \|\mathbf{x}\|^2 \leq r^2\}$$

$$L(\mathbf{x}, \lambda) = \|\mathbf{x} - \mathbf{y}\|^2 + 2\lambda(\|\mathbf{x}\|^2 - r^2) \text{ avec } \lambda \geq 0$$

On a $P_{\mathbb{B}}(\mathbf{y}) = \begin{cases} \mathbf{y} & \text{si } \|\mathbf{y}\|^2 \leq r^2 \\ r \cdot \frac{\mathbf{y}}{\|\mathbf{y}\|} & \text{sinon} \end{cases}$

IV - Sous-différentiel:

Motivation: $\min \frac{1}{2} \|\mathbf{u} - \mathbf{d}\|^2 + \lambda T(\mathbf{u})$ avec $T(\mathbf{u}) = \|\mathbf{D}\mathbf{u}\|$

Théorème: différentiabilité des convexes

Soit $f: C \subset \mathbb{R}^m \rightarrow \mathbb{R}$ convexe avec C convexe.

Soit $\mathbf{x} \in C$, alors $\exists \epsilon > 0$ et $L > 0$ tq $B(\mathbf{x}, \epsilon) \subset C$ et $|f(\mathbf{x}_2) - f(\mathbf{x}_1)| \leq L \|\mathbf{x}_2 - \mathbf{x}_1\|$, $\forall \mathbf{x} \in B(\mathbf{x}_1, \epsilon)$

Consequence: si f est convexe sur C , alors f est différentiable pp sur C .

Définition:

Soit $f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ propre ($\forall x \in \mathbb{R}^n$ et $\text{dom}(f) \neq \emptyset$)

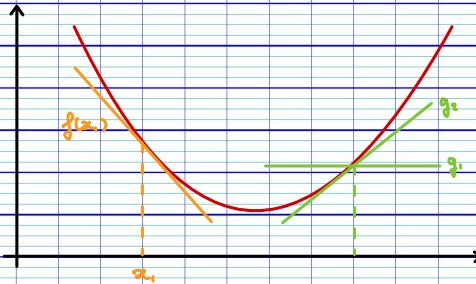
Soit $x \in \text{dom}(f)$

On dit que $g \in \mathbb{R}^n$ est un sous-gradient de f si :

$$f(y) \geq f(x) + \langle g, y - x \rangle, \forall y \in \mathbb{R}^n$$

On appelle sous-differential de f en x , l'ensemble des sous-gradients de f en x :

$$\partial f(x) = \{g \in \mathbb{R}^n : f(y) \geq f(x) + \langle g, y - x \rangle, \forall y \in \text{dom}(f)\}$$



quand f est différentiable convexe
et $f(y) \geq f(x) + \langle g, y - x \rangle$

$y \mapsto f(y) \geq f(x) + \langle g, y - x \rangle$ est une minorante affine de f en x .

Théorème:

Soit $f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ propre. Alors, $\partial f(x)$ est un convexe fermé. $\forall x \in \mathbb{R}^n$.

$$\partial f(x) = \bigcap_{y \in \mathbb{R}^n} \{g : f(y) \geq f(x) + \langle g, y - x \rangle\}$$



Pour $x > 0$: $f(x) = x$ et $\partial f(x) = \{1\}$

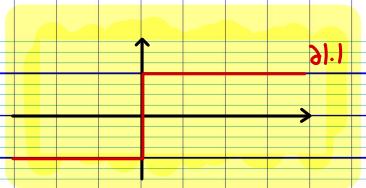
Pour $x < 0$: $f(x) = -x$ et $\partial f(x) = \{-1\}$

Soit $g \in \partial f(0)$, alors $\forall y \in \mathbb{R}$, $|y| \geq 0 + \langle g, y - 0 \rangle$ et $|y| \geq gy$

Pour $|g| \leq 1$ alors d'après l'inégalité du CS :

$$\langle g, y \rangle \leq |g||y| \leq |y| \quad \forall y \in \mathbb{R}$$

$$\text{Inversement, } |g| = \max_{|y| \leq 1} \langle g, y \rangle \leq \max_{|y| \leq 1} |y| = 1$$



Remarque: $\partial f(x)$ est un ensemble qui peut-être = \emptyset

$$\text{On définit } \text{dom}(\partial f) = \{x, \partial f(x) \neq \emptyset\}$$

ex: $f(x) = \begin{cases} -\sqrt{x} & x \geq 0 \\ +\infty & \text{sinon} \end{cases}$ avec $\text{dom}(f) = \mathbb{R}^2$

S'il existe $g \in \partial f(0)$ alors :

$$f(y) \geq f(0) + \langle g, y - 0 \rangle, \text{ soit } -\sqrt{y} \geq yg \quad \forall y \in \mathbb{R}^+$$

Pour $y = 1$: $g \leq -1 < 0$

Pour $y = \frac{1}{2g^2}$, on a: $-\sqrt{\frac{1}{2g^2}} \geq \frac{1}{2g^2} \cdot g = \frac{1}{2g}$

donc $\frac{1}{2g^2} \leq \frac{1}{2g^2}$, ce qui est impossible

donc $\partial f(0) = \emptyset$

Théorème:

Soit $f: \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$ propre, convexe et $\text{dom}(f)$ alors $\partial f(x) \neq \emptyset$ et borné.

Proposition: $\partial f(x) \neq \emptyset \Rightarrow$ convexe

Soit $f: \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$ propre tq $\text{dom}(f)$ est convexe.

Supposons que $\forall x \in \text{dom}(f)$, $\partial f(x) \neq \emptyset$, alors f est convexe.

Théorème :

Soit $f : \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$ convexe propre et $x \in \text{dom}(f) = \text{int}(\text{dom}(f))$.

Si f est différentiable en x , alors $\partial f(x) = \{\nabla f(x)\}$

Inversement, si f admet un unique sous-gradient en x , alors f est différentiable en x et $\partial f(x) = \{\nabla f(x)\}$.

ex: cône normal

Soit $S \subset \mathbb{R}^m$ et $x \in S$

$$\text{Soit } S_S(x) = \begin{cases} 0 & \text{si } x \in S \\ +\infty & \text{sinon} \end{cases}$$

Soit $z \in S$ alors $y \in \partial S(x)$.

$$S_S(y) \geq S_S(z) + \langle y, z - x \rangle, \forall z \in S$$

$$\text{donc } \langle y, z - x \rangle \leq 0, \forall z \in S$$

$$\text{donc } y \in \{g \in \mathbb{R}^m, \langle g, z - x \rangle \leq 0, \forall z \in S\} = N_S(x)$$

Sous-différentielle et optimisation:

Théorème: Fermat

Soit $f : \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$ convexe et propre.

$$\text{Alors, } \underset{x \in \mathbb{R}^m}{\text{Argmin}} f(x) \iff 0_m \in \partial f(x^*)$$

$$f(x) \geq f(x^*) + \langle 0, x - x^* \rangle \text{ et } \forall x \in \text{dom}(f)$$

Théorème: CNS pour $\min_{x \in C} f(x)$

$$\begin{cases} f \text{ convexe} \\ C \text{ convexe} \end{cases}$$

$$x^* \in \operatorname{Argmin}_{x \in C} f(x) \Leftrightarrow 0 \in \partial f(x^*) + N_C(x^*)$$

Si f est différentiable dans x^* , $\partial f(x^*) = \{\nabla f(x^*)\}$

V - Algorithmes proximaux:

Définition: opérateur proximal

Soit $f: \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$. On définit l'opérateur proximal de f par:

$$\operatorname{prox}_f(x) = \operatorname{argmin}_{y \in \mathbb{R}^m} \left\{ \frac{1}{2} \|x-y\|^2 + f(y) \right\}$$

Définition:

On dit qu'une fonction convexe f est fermée si $\forall t \in \mathbb{R}$, $\operatorname{lev}(f, t)$ est fermé.

De façon équivalente, son épigraphe:

$$\operatorname{epi}(f) = \{(x, t) \in \mathbb{R}^{m+1}, f(x) \leq t \text{ et } x \in \operatorname{dom}(f)\}$$



Théorème: 1^{er} théorème du prox

Soit $f: \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$ convexe, propre et fermée.

Alors, $\operatorname{prox}_f(x)$ est un singleton $\forall x \in \mathbb{R}^m$.

Théorème:

Si $y \mapsto f(y) + \frac{1}{2} \|x-y\|^2$ est cohérente alors:

$\forall x \in \mathbb{R}^m$, $\operatorname{prox}_f(x) \neq \emptyset$ et est un singleton.

tend vers l'infini à l'infini

ex:

1) $f = \text{const} = c$ alors $\text{prox}_f(x) = \underset{y \in \mathbb{R}^n}{\text{argmin}} \left\{ \frac{1}{2} \|x - y\|^2 + c \right\} = x$

2) f affine, $f(x) = \langle a, x \rangle + b$ avec $a \in \mathbb{R}^n$ et $b \in \mathbb{R}$

$$\begin{aligned}\text{prox}_f(x) &= \underset{y \in \mathbb{R}^n}{\text{argmin}} \left\{ \frac{1}{2} \|x - y\|^2 + \langle a, y \rangle + b \right\} \\ &= \underset{y \in \mathbb{R}^n}{\text{argmin}} \left\{ \frac{1}{2} \|y - (x - a)\|^2 + \langle a, y \rangle + b - \frac{1}{2} \|a\|^2 \right\} \\ &= x - a\end{aligned}$$

3) f quadratique, $f = \frac{1}{2} x^T A x + b^T x + c$ avec $A \in \mathbb{R}^{n,n}$, $b \in \mathbb{R}^n$ et $c \in \mathbb{R}$

$$\text{prox}_f(x) = \underset{y \in \mathbb{R}^n}{\text{argmin}} \left\{ \frac{1}{2} \|x - y\|^2 + \frac{1}{2} y^T A y + b^T y + c \right\}$$

On a: $\nabla g(y) = y - x + Ay + b$

donc $\nabla g(y) = 0 \Leftrightarrow y = (I + A)^{-1}(x - b)$

i.e. $\text{prox}_f(x) = (I + A)^{-1}(x - b)$

4) $f(x) = \lambda|x|$ avec $x \in \mathbb{R}$ et $\lambda > 0$

$$\text{prox}_f(x) = \underset{y \in \mathbb{R}}{\text{argmin}} \left\{ \frac{1}{2} \|y - x\|^2 + \lambda|y| \right\}$$

$$g(y) = \begin{cases} g_+(y) = \frac{1}{2} (y - x)^2 + \lambda y & \\ \end{cases}$$

$$\begin{cases} g_-(y) = \frac{1}{2} (y - x)^2 - \lambda y & \end{cases}$$

Si le minimum est atteint en $y > 0$:

$$g'_+(y) = 0 \Leftrightarrow y = x - \lambda$$

$$\text{donc } \text{prox}_f(x) = (|x| - \lambda)_+ \cdot \text{sg}(x) = Z_\lambda(x)$$

Règles de calcul:

Soit $f: \prod_{i=1}^m \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$

$$f(x_1, \dots, x_m) = \sum_{i=1}^m f_i(x_i), \quad \forall x_i \in \mathbb{R}^n \text{ et } i=1, \dots, m$$

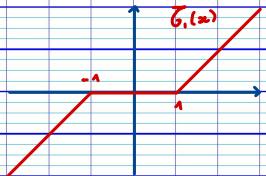
$$\text{prox}_f(x) = \text{prox}_{f_1}(x_1) \times \dots \times \text{prox}_{f_m}(x_m)$$

ex: $f: \mathbb{R}^m \rightarrow \mathbb{R}$ convexe fermée, $f(x) = \sum_{i=1}^n f_i(x)$

alors $\text{prox}_f(x) = (\text{prox}_{f_i}(x))_{i=1}^n$ vecteur

ex: $f: \mathbb{R}^m \rightarrow \mathbb{R}$ et $g(x) = \sum_{i=1}^n f_i(x)$ et $f(x) = s_i \lambda x$
 $x \mapsto \lambda \|x\|_1$

(comme $\text{prox}_g(x) = Z_g(x)$ alors $\text{prox}_f(x) = (Z_{f_i}(x))_{i=1}^n$)



Théorème: composition avec une fonction affine

Soit $g: \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$ convexe, propre et fermée, où $f(x) = g(Ax+b)$, $A: E \rightarrow \mathbb{R}^m$

et $A A^T = d \text{Id}$ avec $d > 0$. Alors:

$$\text{prox}_g(x) = x + \frac{1}{d} A^T \text{prox}_{A^T g}\left((Ax+b)\right)$$

ex: $f: \mathbb{R}^m \rightarrow \mathbb{R}$ avec $a \in \mathbb{R}^m \setminus \{0\}$
 $x \mapsto \|ax\|$

On a: $f(x) = g(a^T x)$ avec $g(t) = \|t\|$

ie $\text{prox}_f = Z_g$ et $A(x) = a^T x$

et $A A^T(x) = \|a\|^2 x$ et $b = 0$ et $d = \|a\|^2$

donc $\text{prox}_f(x) = x + \frac{1}{\|a\|^2} (Z_{\|a\|^2}(a^T x) - a^T x) a$

Retour sur la projection:

Soit $g: \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$ avec $g(x) = S_C(x)$ et $C \subseteq \mathbb{R}^m$ non vide

Théorème: $\text{prox}_g(x) = \underset{y \in C}{\operatorname{argmin}} \left\{ \frac{1}{2} \|x-y\|^2 + S_C(y) \right\}$ où $S_C(x) = \begin{cases} 0 & \text{si } x \in C \\ +\infty & \text{sinon} \end{cases}$

Théorème:

Sont f une fonction convexe, propre et fermée, alors :

$\forall x, y \in \mathbb{R}^n$,

$$y = \text{prox}_f(x) \Leftrightarrow x - y \in \partial f(y) \Leftrightarrow \langle x - y, y - z \rangle \leq f(z) - f(y), \forall z \in \mathbb{R}^n$$

ex: $y = \text{prox}_g(x) = \underset{z \in \mathbb{R}^n}{\operatorname{argmin}} \frac{1}{2} \|y - z\|^2 + g(z)$ alors $0 \in \partial g(y) = \nabla_g \left(\frac{1}{2} \|y - z\|^2 \right) + \partial f(y)$

Descr. de gradient proximal:

$$\min_{x \in \mathbb{R}^n} F(x) = f(x) + g(x) \quad \begin{cases} g: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\} \text{ convexe, propre et fermée} \\ f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\} \end{cases}$$

On a $\text{dom}(f)$ convexe et $\text{dom}(g) \subseteq \text{int}(\text{dom}(f))$

$f \in C_L^{1,1}$ et on suppose que $\operatorname{argmin} F \neq \emptyset$

ex: i. si $g = 0$, $\text{dom}(f) = \mathbb{R}^n$ $\min_{x \in \mathbb{R}^n} f(x)$

ii. si $g = S_c$, $c \in \mathbb{R}^n$ convexe, fermée et non vide $\min_{x \in c} f(x)$

iii. si $g = \lambda \|x\|_1$, $\min_{x \in \mathbb{R}^n} f(x) + \lambda \|x\|_1$

Rappel: on avait génér. une suite $(x_n)_n$ avec :

$$x_{n+1} = \text{Proj}_{c_n} (x_n - t_n \nabla f(x_n))$$

\Leftrightarrow

$$x_{n+1} = \underset{x}{\operatorname{argmin}} \left\{ f(x_n) + \langle \nabla f(x_n), x - x_n \rangle + \frac{1}{2t_n} \|x - x_n\|^2 \right\}$$

appli du lemme

max

Rappel: $\min_{x \in C} f(x) = (f(x) + S_{\text{prox}} \text{ min prox. } - S_0)$

Itération de l'algorithme du gradient proximal (PCM)

$$x_{k+1} = \text{prox}_{\lambda L^{-1}}(x_k - \frac{1}{\lambda} \nabla f(x_k))$$

On cherche: $\min_{x \in \mathbb{R}^n} F = f + g$

i. g convexe, propre et fermée ($g \in \Gamma'$)

ii. $f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$, propre, fermée, dom f convexe et $\text{dom}(g) \subseteq \text{int}(\text{dom}(f))$ et $f \in C_{L_f}^{1,1}$

iii. $\text{argmin } F \neq \emptyset$

PGM: Initialisation: $x_0 \in \text{int}(\text{dom}(f))$

Étapes: i. $\forall k \geq 0$, choisir $t_k > 0$

$$\text{ii. } x_{k+1} = \text{prox}_{\frac{\lambda}{L} \nabla f(x_k)}(x_k - \frac{1}{\lambda} \nabla f(x_k)) = T_{\frac{1}{\lambda} \nabla f}(x_k)$$

→ critères d'arrêt: $\|x_{k+1} - x_k\|, \|\nabla f(x_k)\|, \|x_k\|, \dots \leq \varepsilon$

$$O\left(\frac{1}{k}\right)$$

- ex: i. $\min_{x \in \mathbb{R}^n} f(x) \rightarrow x_{k+1} = x_k - t_k \nabla f(x_k)$ GM

ii. $\min_{x \in \mathbb{R}^n} f(x) \rightarrow x_{k+1} = \text{Proj}_C(x_k - t_k \nabla f(x_k))$ PGM

iii. $\min_{x \in \mathbb{R}^n} (f(x) + \lambda \|x\|) \rightarrow x_{k+1} = T_{\frac{1}{\lambda} \nabla f}(x_k - t_k \nabla f(x_k))$ ISTA: iterative shrinkage thresholding algo

lemme de descente:

Sous les mêmes hypothèses

$\forall x \in \text{int}(\text{dom}(f))$ et $L \in \left[\frac{L_f}{3}, +\infty\right[$, on a:

$$F(x) - F(T_L(x)) \geq \left(\frac{L-L_f}{L}\right) \|G_L^{1,1}(x)\|^2 \quad \text{où } G_L^{1,1}: \text{int}(\text{dom}(f)) \rightarrow \mathbb{R}^n$$

$$x \longrightarrow L(x - T_L(x))$$

On appelle $G_L^{1,1}$: "gradient mapping"

On observe que:

$$x_{k+1} = T_L(x_k) = x_k - \frac{1}{L} (G_L(x_k))$$

Remarque: quand $f=0$: $x_{k+1} = \text{prox}_{Lg}(x_k)$ (algo du point proximal)

Théorème:

Sous les mêmes hypothèses et en supposant en plus que f est convexe. Soit (x_k) la suite générée par l'algorithme de gradient proximal. Alors:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{k}, \quad \forall x^* \in \text{argmin}(F)$$

Descente de gradient proximal accélérée: i. $g \in I$.

ii. $f: \mathbb{R}^n \rightarrow \mathbb{R}$ $\text{telle que } f_g \text{ est convexe}$

iii. $\text{argmin}(F + f_g) \neq \emptyset$

$f \in C^{1,1}$

point proximal gradient méthod

FISTA: Initialisation: prendre $x_0, y_0 = x_0$ et $b = 1$

Étapes: i. pour $k \geq 0$, choisir $L_k > 0$

$$\text{i. } x_{k+1} = \text{prox}_{L_k g}(y_k - \frac{1}{L_k} \nabla f(y_k))$$

$$\text{ii. } t_{k+1} = 1 + \sqrt{1 + b_k^2}$$

$$\text{iii. } y_{k+1} = x_{k+1} + \left(\frac{t_{k+1}}{t_k} \right) (x_{k+1} - x_k)$$

$$O\left(\frac{1}{k^2}\right)$$

Convergence de FISTA: $f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{(k+1)^2}, \quad \forall x^* \in \text{argmin}(F)$

ex: $\min \frac{1}{2} \|Ax - b\|^2 + \lambda \|x\|$ avec $\begin{cases} A \in \mathbb{R}^{n \times m}, \quad \forall \lambda > 0 \\ b \in \mathbb{R}^m \end{cases}$

$$\text{Maj } L_f = \lambda \max(A^T A)$$

$$\begin{cases} x_{k+1} = \frac{\tau_\lambda}{L_f} (y_k - \frac{1}{L_f} A^T (A y_k - b)) \\ t_{k+1} = 1 + \sqrt{1 + b_k^2} \end{cases}$$

$$y_{k+1} = x_{k+1} + \frac{t_{k+1}}{t_k} (x_{k+1} - x_k)$$

Duality: $\min_x f(x)$ $\max_y \phi(y)$
problème primaire problème dual

Définition: Complément de Fenchel - Legendre

Soit $f: \mathbb{R}^m \rightarrow \mathbb{R} \cup \{\infty\}$.

On définit son complément par:

$$f^*: \begin{cases} \mathbb{R}^m \rightarrow \overline{\mathbb{R}} \\ y \mapsto f^*(y) = \sup_x (\langle x, y \rangle - f(x)) \text{ et } S_c(x) = \begin{cases} 0 & \text{si } x \in C \\ \infty & \text{si } x \notin C \end{cases} \end{cases}$$

ex: $f^*(y) = \sup_{x \in C} \langle x, y \rangle - S_c(x)$
 $= \sup_{x \in C} \langle x, y \rangle = S_c(y)$ fonction support de C

Propriétés de f^* :

i. $f^* \in M$. $\{x, f(x) \neq 0\} \neq \emptyset$

ii. $f: \mathbb{R}^m \rightarrow \mathbb{R} \cup \{\infty\}$ propre

$\forall x, y \in \mathbb{R}^m, \langle x, y \rangle \leq f^*(y) + f(x)$ Inégalité de Fenchel

Théorème:

Soit $f: \mathbb{R}^m \rightarrow \mathbb{R} \cup \{\infty\}$ convexe et propre.

$\langle z, y \rangle = f^*(y) + f(z) \Leftrightarrow y \in \partial f(z)$ ♥ preuve exo

Si en plus f est fermée, alors:

$y \in \partial f(x) \Leftrightarrow x \in \partial f^*(y)$ essence de la dualité

Bicomjugui:

$$f^{**}(x) = \sup_{y \in \mathbb{R}^n} \langle x, y \rangle - f^*(y) \quad \text{avec } f: E \rightarrow \mathbb{R} \cup \{+\infty\} \text{ et } \langle \cdot, \cdot \rangle_{\mathbb{R}^n}$$

Théorème:

Soit $f \in \Gamma_c(\mathbb{R}^n)$ alors $f^{**} = f$.

Règles de calcul:

Théorème: fonctions séparables

Soit $g: \mathbb{R}^{n_1} \times \dots \times \mathbb{R}^{n_p} \rightarrow \mathbb{R} \cup \{+\infty\}$ définie par $g(x_1, \dots, x_p) = \sum_{i=1}^p f_i(x_i)$ où $f_i: \mathbb{R}^{n_i} \rightarrow \mathbb{R} \cup \{+\infty\}$ propres.

Alors :

$$g^*(y_1, \dots, y_p) = \sum_{i=1}^p g_i^*(y_i), \quad y_i \in \mathbb{R}^{n_i} \text{ pour } i=1, \dots, p$$

Démonstration:

Soient $(y_1, \dots, y_p) \in \mathbb{R}^{n_1} \times \dots \times \mathbb{R}^{n_p}$, on a :

$$\begin{aligned} g^*(y_1, \dots, y_p) &= \sup_{\substack{x_1 \in \mathbb{R}^{n_1} \\ \dots \\ x_p \in \mathbb{R}^{n_p}}} \langle (y_1, \dots, y_p), (x_1, \dots, x_p) \rangle - g(x_1, \dots, x_p) \\ &= \sup_{\substack{x_1 \in \mathbb{R}^{n_1} \\ \dots \\ x_p \in \mathbb{R}^{n_p}}} \sum_{i=1}^p \langle y_i, x_i \rangle - \sum_{i=1}^p f_i(x_i) \\ &= \sum_{i=1}^p \sup_{\substack{x_i \in \mathbb{R}^{n_i} \\ \dots \\ x_i \in \mathbb{R}^{n_i}}} \langle y_i, x_i \rangle - f_i(x_i) \\ &= \sum_{i=1}^p f_i^*(y_i) \end{aligned}$$

Théorème: changement de variable affine

Soit $f: \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$ et $A \in GL_m(\mathbb{R})$, où $a, b \in \mathbb{R}^m$ et $c \in \mathbb{R}$.

Alors la conjugaison du fonctionnel de grew est $g(x) = f(A(x-a)) + \langle b, x \rangle + c$ est donnée par:

$$g^*(y) = f^*((A^T)^{-1}(y-b)) + \langle a, y-b \rangle - c, \forall y \in \mathbb{R}^m$$

Démonstration:

Soit $y \in \mathbb{R}^m$:

$$\begin{aligned} g^*(y) &= \sup_{x \in \mathbb{R}^m} \langle x, y \rangle - g(x) \\ &= \sup_{x \in \mathbb{R}^m} \langle x, y \rangle - f(A(x-a)) - \langle b, x \rangle - c \quad \text{--- } \textcolor{green}{g = A(x-a)} \\ &= \sup_{x \in \mathbb{R}^m} \langle y, A^T(x+a) \rangle - f(x) - \langle b, A^T(x+a) \rangle - c \\ &= \langle a, y-b \rangle - c + \sup_{x \in \mathbb{R}^m} \langle y-b, A^T(x) \rangle - f(x) \quad \text{--- } \langle x, A^T y \rangle = \langle A^T x, y \rangle \\ &= \langle a, y-b \rangle - c + \sup_{x \in \mathbb{R}^m} \langle (A^T)^{-1}(y-b), x \rangle - f(x) \\ &= f^*((A^T)^{-1}(y-b)) + \langle a, y-b \rangle - c \end{aligned}$$

Proposition:

Soit $f: \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$ et $\lambda > 0$:

- pour $g(x) = \lambda f(x)$, on a: $g^*(y) = \lambda f^*\left(\frac{y}{\lambda}\right)$
- pour $g(x) = \lambda f\left(\frac{x}{\lambda}\right)$, on a: $g^*(y) = \lambda f^*\left(\frac{y}{\lambda}\right)$

Démonstration:

Soit $y \in \mathbb{R}^m$:

$$\begin{aligned} g^*(y) &= \sup_{x \in \mathbb{R}^m} \langle x, y \rangle - g(x) \\ &= \sup_{x \in \mathbb{R}^m} \langle x, y \rangle - \lambda f(x) \\ &= \sup_{x \in \mathbb{R}^m} \lambda \left(\langle x, \frac{y}{\lambda} \rangle - f(x) \right) \\ &= \lambda \sup_{x \in \mathbb{R}^m} \left(\langle \frac{x}{\lambda}, y \rangle - f(x) \right) \\ &= \lambda f^*\left(\frac{y}{\lambda}\right) \end{aligned}$$

ex:

$$1) f(x) = \frac{1}{p} |x|^p \text{ pour } p > 1$$

$$\text{alors } f^*(y) = \sup_{\mathbf{x}} \langle \mathbf{x}, y \rangle - \frac{1}{p} |\mathbf{x}|^p \text{ et } (|x|)^p = \frac{|x|}{|x|}$$

$$= \sup_{\mathbf{x}} \langle \mathbf{x}, y \rangle - f(\mathbf{x})$$

$$= \sup_{\mathbf{x}} h(\mathbf{x})$$

avec $h(\mathbf{x}) = \langle \mathbf{x}, y \rangle - \frac{1}{p} |\mathbf{x}|^p$, qui est concave

$$\text{on a: } h'(\bar{\mathbf{x}}) = y - \text{sg}(\bar{\mathbf{x}}) |\bar{\mathbf{x}}|^{p-1} = 0 \Rightarrow y = \text{sg}(\bar{\mathbf{x}}) |\bar{\mathbf{x}}|^{p-1}$$

$$\text{donc } \text{sg}(y) = \text{sg}(\bar{\mathbf{x}}) \text{ i.e. } |y| = |\bar{\mathbf{x}}|^{p-1}$$

$$\text{soit } \bar{\mathbf{x}} = \text{sg}(y) |y|^{\frac{1}{p-1}}$$

$$\text{donc } h(\bar{\mathbf{x}}) = \text{sg}(y) |y| |y|^{\frac{1}{p-1}} - \frac{1}{p} |y|^{p-1}$$

$$= |y| \cdot |y|^{\frac{1}{p-1}} - \frac{1}{p} |y|^{p-1}$$

$$\text{ainsi: } f^*(y) = h(\bar{\mathbf{x}}) = \left(1 - \frac{1}{p}\right) |y|^{\frac{p}{p-1}}$$

$$\text{Soit } q \text{ tq } \frac{1}{p} + \frac{1}{q} = 1$$

$$\text{On trouve finalement: } f^*(y) = \frac{1}{q} |y|^q$$

$$2) \text{ Soit } f: \mathbb{R}^m \rightarrow \mathbb{R}$$

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{z} \end{bmatrix} \rightarrow \frac{1}{2} \mathbf{z}^T A \mathbf{z} + \mathbf{b}^T \mathbf{z} + c$$

$$f^*(y) = \sup_{\mathbf{x}} \langle \mathbf{x}, y \rangle - f(\mathbf{x})$$

$$= \sup_{\mathbf{x}} h(\mathbf{x}) \text{ avec } h(\mathbf{x}) = -\frac{1}{2} \mathbf{z}^T A \mathbf{z} - \mathbf{b}^T \mathbf{z} - c + \langle \mathbf{x}, y \rangle$$

On trouve :

$$f^*(y) = \frac{1}{2} (y - b)^T A^{-1} (y - b) - c$$

Dualité de Frenchel - Rockafellar:

$$(P): \min_{\mathbf{x}} h(A\mathbf{x}) + g(\mathbf{x}) \quad \text{primal}$$

$$\text{avec } \begin{cases} h: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\} \\ g: \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\} \end{cases} \text{ propres}$$

$$\begin{cases} A: \mathbb{R}^m \rightarrow \mathbb{R}^n \\ \text{optimisation linéaire} \end{cases}$$

Le problème dual associé à (P) s'écrit :

$$(D): \max_{y \in \mathbb{R}^m} -f^*(y) - g^*(-A^*y)$$

On a : $\min_{x \in \mathbb{R}^n} f(x) + g(x) = \min_{x \in \mathbb{R}^n} f(x) + g(Ax), z = Ax$

Le Lagrangien du problème s'écrit :

$$\begin{aligned} L(x, z, y) &= f(z) + g(x) + \langle y, Ax - z \rangle \\ &= (-\langle y, Ax \rangle - g(x)) - (\langle y, z \rangle - h(y)) \end{aligned}$$

donc $\sup_{x, z} L(x, z, y) = -h^*(y) - g^*(-A^*y) = q(y)$

ex: $f: \begin{cases} \mathbb{R}^m \rightarrow \mathbb{R} \\ x \mapsto \frac{1}{2} x^T A x + b^T x + c \end{cases}$, avec $\begin{cases} A \in \mathbb{S}_n^+ \\ b \in \mathbb{R}^n \\ c \in \mathbb{R} \end{cases}$

$$Mq: f^*(y) = \frac{1}{2} (y - b)^T A^{-1} (y - b) - c$$

$$\text{On a } f^*(y) = \sup_{x \in \mathbb{R}^n} \langle x, y \rangle - f(x) = \sup_{x \in \mathbb{R}^n} \langle x, y \rangle - \frac{1}{2} x^T A x - \langle b, x \rangle - c$$

& (x) concave.

On peut écrire : $h(x) = \langle x, y - b \rangle - \frac{1}{2} x^T A x - c$

$$\nabla_x h(x) = (y - b) - Ax = 0 \rightarrow x = A^{-1}(y - b) \text{ est donc le maximum de } h$$

donc $f^*(y) = h(\bar{x})$

$$\begin{aligned} &= \langle A^{-1}(y - b), y - b \rangle - \frac{1}{2} (A^{-1}(y - b))^T A A^{-1}(y - b) - c \\ &= (y - b)^T A^{-1}(y - b) - \frac{1}{2} (y - b)^T A^{-1}(y - b) - c \\ &= \frac{1}{2} (y - b)^T A^{-1}(y - b) - c \end{aligned}$$

ex: $f: \begin{cases} \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\} \\ x \mapsto \begin{cases} -\sum_{i=1}^n \log(x_i) & \text{si } x > 0 \\ +\infty \text{ sinon} \end{cases} \end{cases}$

On a $f^*(y) = \sup_{x \in \mathbb{R}^n} \langle x, y \rangle - f(x)$

$$\begin{aligned} &= \sup_{x \in \mathbb{R}^n} \sum_{i=1}^n x_i y_i + \log(x_i) \\ &\quad \text{g(x) = } \begin{cases} \langle -x, y \rangle + f(x) & \text{si } x > 0 \\ +\infty & \text{sinon} \end{cases} \end{aligned}$$

Si $y > 0 \Leftrightarrow \forall i, y_i > 0$ alors $f^*(y) = +\infty$

Si $y < 0$, $\nabla g(\bar{x}) = -\bar{x} - \frac{1}{y_i} = 0 \rightarrow \bar{x}_i = \frac{1}{y_i}$

alors $f^*(y) = g(\bar{x}) = -n - \sum_{i=1}^n \log(-y_i)$

Si l'on connaît que : $f(x) = \sum_{i=1}^m g_i(x)$ avec $g_i(t) = \begin{cases} -\log(t) & si t > 0 \\ +\infty sinon \end{cases}$

On a : $g^*(t) = \sup_{x \in \mathbb{R}^n} st + \log(g_i(x))$

$$f'(t) = s + \frac{1}{t} \text{ alors } t = -\frac{1}{s}$$

donc $f^*(y) = \begin{cases} \sum_{i=1}^m g^*(y_i) & \\ +\infty \end{cases}$

ex: $f: \begin{cases} \mathbb{R}^n \rightarrow (-\infty, +\infty) \\ x \mapsto \begin{cases} \sum_{i=1}^m x_i \log(x_i) & si x > 0 \\ +\infty sinon \end{cases} \end{cases}$

On peut écrire : $f(x) = \sum_{i=1}^m g_i(x_i)$

avec $g_i(t) = \begin{cases} t \log(t) & si t > 0 \\ +\infty sinon \end{cases}$

Retour sur la dualité de Frenchel-Rockfeller :

$$(P): \min_{x \in \mathbb{R}^n} f(Ax) + g(x)$$

$$(D): \max_{y \in \mathbb{R}^m} -f^*(y) - g^*(-A^T y)$$

$$\begin{aligned} \text{Val}(P) &= \min_x f(Ax) + g(x), \quad \forall y \in \text{dom}(g^*) \text{ et } f(x) + g(x) \geq \langle x, y \rangle \\ &\geq \min_x \langle y, Ax \rangle - f^*(y) - g(x) \\ &= -f^*(y) - \sup_x \langle -A^T y, x \rangle - g(x) \\ &= -f^*(y) - g^*(-A^T y) \end{aligned}$$

donc $\text{Val}(P) \geq \text{Val}(D) = \max_y -f^*(y) - g^*(-A^T y)$

Théorème de Frenchel-Rockfeller:

$f, g \in \Gamma'$ avec 1 expression linéaire si le "problème n'est pas dégénéré" alors:

$$\text{Val}(P) = \text{Val}(D)$$

(*) : $x \in c : (\text{dom}(h)) \setminus A(c : (\text{dom} g))$

$$\alpha(C) = \{x \in \text{Aff}(c), B_r(x, \epsilon) \cap \text{Aff}(c) \subseteq C\}$$

(P)	(D)
$\min_{x \in K} \frac{1}{2} \ Ax - b\ ^2 + \ x\ _1$	$\max_y -\frac{1}{2} \ y\ ^2 - \langle b, y \rangle \text{ avec } \ \mathcal{A}^T y\ _1 \leq 1$
$\min_{x \in K} \ Ax - b\ _p$	$\max_y -\ \mathcal{A}^T y\ _p - \langle b, y \rangle$
$\min_{x \in K} \langle c, x \rangle, Ax = b, x \in K$	$\max \langle b, q \rangle, \mathcal{A}^T y - c \in K^\circ$

Pour l'exam: 1) ∇

2) sous-diff

3) prox

4) conjugate function

5) MiKrode grad

6) conditions KKT

7) min/max locaux

8) min/max globaux